Cours de révision en 10 questions

Examen individuel : 30 minutes, 5 questions, 5 points. Les cinq questions seront choisies parmi les dix ci-dessous et reprises à l'identique. Chaque question vaut 1 point. Les réponses proposées peuvent être apprises par cœur ; toute formulation équivalente et correcte sera acceptée.

Préparez les dix réponses. Pour la question 2, rédigez votre application personnelle au projet. Aucun code Python n'est demandé. Épreuve sans documents ni outils numériques.

1. Que signifie QUID et à quoi sert chaque élément ?

Réponse à connaître
Q = Question : le problème que l'on veut traiter.
U = Unité : ce que représente une observation, généralement une ligne du tableau.
I = Indicateur : la mesure qui décrit le résultat étudié.
D = Décision : l'action que l'analyse ou la prédiction permet d'éclairer.

Exemple
Pour les offres d'emploi : estimer un salaire ; une ligne représente une offre ; l'indicateur est le salaire annuel brut en euros ; la décision est de comparer une offre à des offres similaires.

À retenir : Ne pas confondre l'unité d'observation (« une offre ») et l'unité de mesure (« euros par an »).

2. Comment appliquez-vous le QUID à votre projet ?

Réponse à connaître
Je formule **notre question précise**, puis je définis **notre unité d'observation**, **notre indicateur** et **la décision visée**. Je précise ce que l'application apporte à son utilisateur. La réponse doit correspondre aux données réellement disponibles.

Exemple
Cinéma : quels films recommander à un utilisateur à partir de ses avis passés ? Une observation = un avis d'un utilisateur sur un film. Indicateur d'évaluation = rappel à 5. Décision = quels cinq films proposer. Le rappel mesure la part des films appréciés masqués retrouvés dans les cinq suggestions.

À retenir : Préparez votre propre réponse en quatre lignes : Q : … ; U : … ; I : … ; D : … . Il n'est pas obligatoire d'avoir une cible supervisée pour appliquer QUID.

3. Quelles sont les grandes étapes d'un projet data et quel est leur rôle ?

Réponse à connaître
1. Cadrer la question et la décision attendue.
2. Collecter et préparer des données pertinentes, comprendre leur qualité et les nettoyer.
3. Explorer les distributions, les relations et les limites.
4. Construire et évaluer une méthode face à une référence simple, sur des données séparées.
5. Intégrer et communiquer : créer l'application, tester son fonctionnement, documenter les résultats et les limites.

Exemple
Pour le salaire : définir ce qu'on estime, harmoniser les montants, explorer les écarts, comparer un modèle à la médiane, puis créer une interface d'estimation.

À retenir : Réserver les données avant les transformations apprises et l'entraînement. Dans la pratique, on peut revenir à une étape précédente.

Cours de révision en 10 questions

4. À quoi sert l’analyse exploratoire des données ?

Réponse à connaître
L’**analyse exploratoire** sert à comprendre le jeu de données avant de modéliser : types de variables, distributions, valeurs manquantes, doublons, valeurs inhabituelles et relations entre variables. Elle aide à vérifier la faisabilité de la question et à choisir des variables pertinentes.

Exemple
Pour les salaires : observer leur distribution, vérifier les unités, repérer les montants absents et comparer les valeurs selon les métiers.

À retenir : Une corrélation décrit une association ; elle ne prouve pas qu’une variable en cause une autre.

5. Quelle différence entre une base relationnelle et une base documentaire ?

Réponse à connaître
Une **base relationnelle** organise les données en tables, avec des lignes et des colonnes. Des clés permettent de relier les tables. Une **base documentaire** stocke des documents structurés, souvent de type JSON, dont les champs peuvent varier. Le choix dépend de la structure des données et des accès attendus.

Exemple
Relationnelle : clients, commandes et produits reliés entre eux. Documentaire : catalogue de produits dont les caractéristiques varient selon la catégorie.

À retenir : Une base documentaire appartient à la famille NoSQL. NoSQL regroupe plusieurs modèles ; il ne signifie pas « toujours meilleur que SQL ».

6. Comment choisir un type de base de données selon un besoin ?

Réponse à connaître
Je regarde **la structure des données**, **leurs relations** et **les opérations les plus fréquentes**. Je choisis une base adaptée à ces besoins et je justifie ce choix. Il n’existe pas de type de base meilleur pour tous les usages.

Exemple
Pour gérer des commandes liées à des clients et à des produits, une base relationnelle convient car les relations et la cohérence sont importantes. Pour un catalogue aux attributs variables, une base documentaire peut être adaptée.

À retenir : À l’examen, donnez un besoin concret, nommez le type choisi et expliquez le lien entre les deux.

Cours de révision en 10 questions

7. Quelle différence entre apprentissage supervisé et non supervisé ?

Réponse à connaître
En **supervisé**, les exemples d'entraînement contiennent une réponse connue, appelée cible **y**. Le modèle apprend à prédire cette réponse à partir des entrées **X**. En **non supervisé**, aucune cible n'est fournie pour guider l'apprentissage : on recherche une structure, par exemple des groupes de profils similaires.

Exemple
Supervisé : apprendre l'espèce d'une fleur à partir de fleurs étiquetées. Non supervisé : regrouper des utilisateurs selon leurs goûts, sans groupe fourni à l'avance.

À retenir : Le clustering constitue des groupes ; une règle supplémentaire est nécessaire pour transformer ces groupes en recommandations.

8. Quelle différence entre classification et régression ?

Réponse à connaître
La **classification** prédit une catégorie : oui/non, une espèce, un type de résultat. La **régression** prédit une quantité numérique : un salaire, une durée ou un prix. Les deux sont des formes d'apprentissage supervisé lorsque la réponse est connue dans les exemples d'entraînement.

Exemple
Prédire victoire à domicile ou non : classification. Prédire un salaire annuel en euros : régression. Prédire l'espèce d'un iris : classification.

À retenir : Le nom « régression logistique » peut tromper : dans nos exemples, cet algorithme fait de la classification.

Pour réviser : cachez la réponse, reformulez-la à voix haute, puis vérifiez les mots importants. Sur votre copie, répondez directement à la question et justifiez avec des phrases courtes.

Cours de révision en 10 questions

9. À quoi servent les ensembles train, validation et test ?

Réponse à connaître
Le **train** sert à apprendre les transformations et le modèle. La **validation** sert à comparer les méthodes et choisir les réglages. Le **test** reste réservé à l'évaluation finale, une fois les choix fixés. Le découpage doit reproduire l'usage visé et empêcher le passage d'informations futures dans l'apprentissage.

Exemple
Pour le football : matchs anciens pour le train, période suivante pour la validation, matchs les plus récents pour le test. Pour le cinéma : conserver certains avis et en masquer d'autres sans les utiliser pour construire les profils.

À retenir : Imputation, standardisation et encodage appris : ajustement sur train, puis application aux autres ensembles. Après le choix, on peut réentraîner sur train + validation avant le test final.

10. Qu'est-ce qu'une référence simple et pourquoi un score élevé ne suffit-il pas ?

Réponse à connaître
Une **référence simple**, ou baseline, donne un point de comparaison facile à reproduire. On peut prédire la classe majoritaire du train, le salaire médian du train ou les films populaires. Un score élevé ne suffit pas : il faut comparer à cette référence sur les mêmes données, vérifier le découpage, les fuites d'information et les erreurs.

Exemple
Si 95 % des observations d'un test sont négatives, toujours répondre « négatif » donne déjà 95 % d'accuracy. Le modèle doit montrer ce qu'il apporte face à cette règle.

À retenir : Le modèle peut aussi obtenir un score trompeur s'il reçoit une information future ou si des doublons contaminent le test. Même une bonne prédiction doit correspondre à un usage utile.

Pour réviser : cachez la réponse, reformulez-la à voix haute, puis vérifiez les mots importants. Sur votre copie, répondez directement à la question et justifiez avec des phrases courtes.